Priorización de tareas con Qwen3.5-4B

Hackathon 8. Diseño factorial duplicado y comparación de métodos PEFT

1. Problema y evaluación

Una oficina universitaria recibe tareas con plazos, impactos y dependencias distintos. El objetivo es asignar una prioridad consistente a partir del texto, sin confundir el tono enfático con los hechos. La salida JSON informa **prioridad, escalamiento, bloqueo y criterio decisivo**. El error más delicado es relegar una tarea crítica.

Si los criterios ya llegan estructurados, basta aplicar las reglas directamente. Aquí se estudia si el modelo aprende a interpretarlas en descripciones libres; su uso con solicitudes reales necesitaría validación humana.

Prioridad	Regla, aplicada en este orden
Crítica	Riesgo activo de seguridad o exposición de datos; también interrupción total para al menos 50 personas sin alternativa.
Alta	Plazo de hasta 8 h con impacto medio/alto o al menos 3 tareas dependientes; también impacto alto sin alternativa.
Media	Plazo de hasta 48 h, impacto medio/alto o al menos una tarea dependiente.
Baja	Demás casos. Un bloqueo se informa y no reduce la prioridad.

Los datos son **sintéticos en español**: 256 ejemplos de entrenamiento, 48 de validación, 64 de prueba y 16 casos difíciles. Se añade una comprobación final de 128 casos nuevos. Las familias de tareas están separadas y cada partición está equilibrada. Se verifican etiquetas, límites de decisión y monotonía del impacto. F1 macro da el mismo peso a las cuatro prioridades; una salida inválida cuenta como error y no se repara.

2. Diseño factorial y réplicas

Factor	Niveles
Rango r	2, 8 y 32
Alpha	8 y 32
Ronda / semilla	Primera: 42. Segunda: 43. Cada ronda incluye las seis combinaciones.

Seis combinaciones por dos réplicas: doce entrenamientos. Se prueban primero las cuatro esquinas y se completa el nivel intermedio. La semilla es un bloque de réplica. En LoRA estándar la escala es alpha/r, por lo que se estudia también la interacción entre factores. El orden y las reglas se fijan en factorial/plan.json antes de observar las nuevas ejecuciones.

Se mantiene Qwen3.5-4B en NF4, dropout 0.05, tasa máxima 0.0002, 32 actualizaciones y lote efectivo 8. Cada condición recarga el modelo original y ve las mismas particiones. Se ajusta una superficie de respuesta y se comprueba el candidato propuesto. Además se mide r=64 por duplicado, fuera del intervalo original [2,32]. El LoRA seleccionado se compara con DoRA, rsLoRA y LoRA+, cada uno con dos semillas.

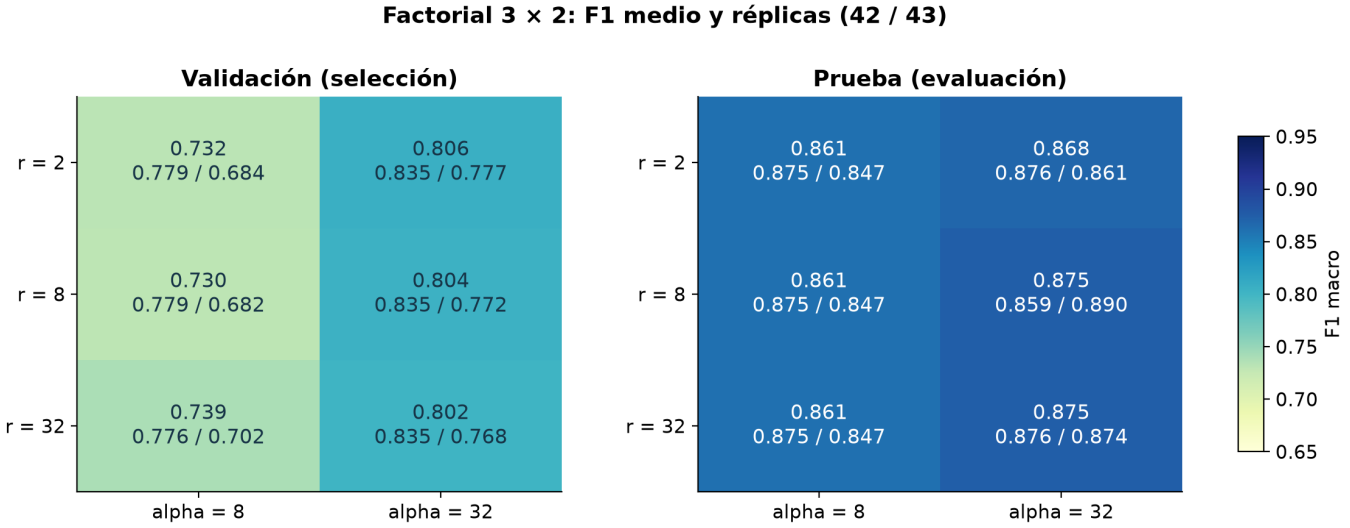
Toda la ampliación utiliza **g002, NVIDIA RTX A6000**, reserva de 7 shards, 4 CPU y 32 GiB de RAM. Los jobs son 58225 y 58227. La GPU es compartida. Los tiempos de la etapa inicial en ds001 no se mezclan con este factorial.

Resultados del diseño factorial

3. Las doce ejecuciones

r	alpha	Semilla	F1 valid.	F1 prueba	Tiempo (min)	VRAM (GiB)	Latencia (s)
2	8	42	0.779	0.875	3.79	3.20	1.41
2	8	43	0.684	0.847	3.78	3.20	1.64
2	32	42	0.835	0.876	3.52	3.20	1.63
2	32	43	0.777	0.861	3.77	3.20	1.65
8	8	42	0.779	0.875	3.52	3.25	1.61
8	8	43	0.682	0.847	3.52	3.25	1.61
8	32	42	0.835	0.859	3.51	3.25	1.62
8	32	43	0.772	0.890	3.73	3.25	1.65
32	8	42	0.776	0.875	3.54	3.42	1.63
32	8	43	0.702	0.847	3.69	3.44	1.65
32	32	42	0.835	0.876	3.79	3.42	1.64
32	32	43	0.768	0.874	3.76	3.44	1.65

La selección usa validación. Prueba y casos difíciles describen generalización. El detalle por campo, errores críticos, parámetros, tiempos de calentamiento y predicciones crudas se conserva en experiments.csv y los JSONL de cada condición.

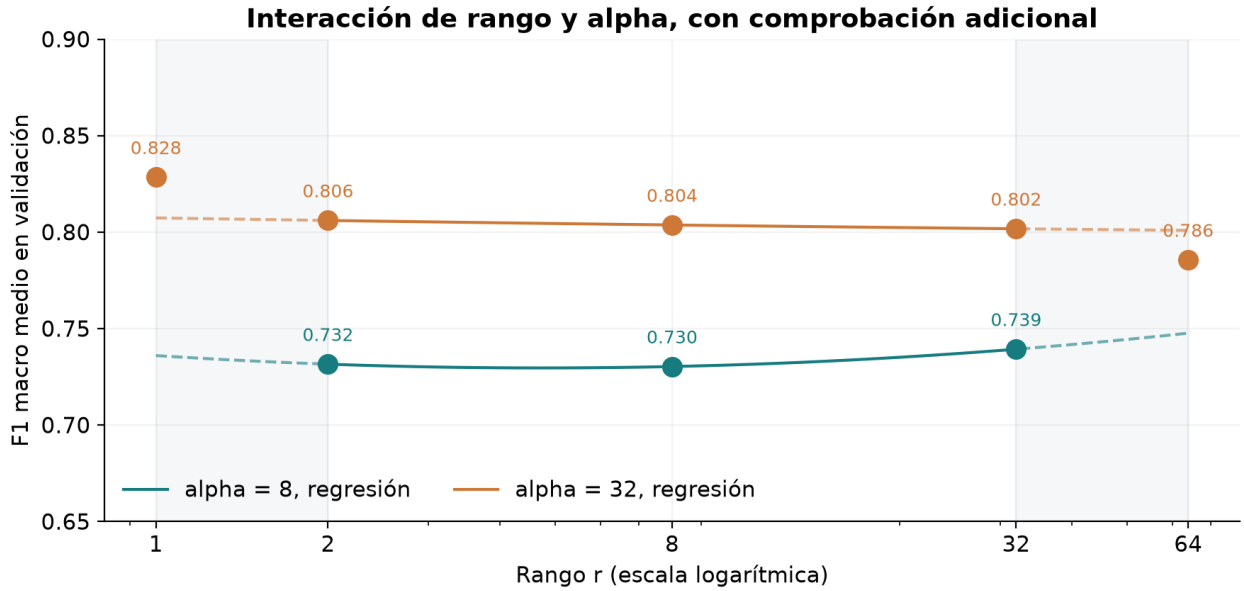


Cada celda muestra F1 medio y los resultados individuales de las semillas 42 / 43. El promedio no reemplaza la inspección de la variación entre réplicas.

Interacción y comprobación del óptimo

4. Superficie de respuesta

Se ajusta una regresión cuadrática en log2(r), con alpha como factor de dos niveles, sus interacciones y el bloque de semilla. El modelo representa efectos principales y permite comprobar si aumentar r produce cambios distintos según alpha. Con dos niveles no se puede estimar la curvatura propia de alpha.



Puntos: mediciones duplicadas. Línea continua: ajuste. Línea discontinua: extrapolación.

Efecto	gl	F parcial	p exploratoria
r	2	0.093	0.9131
alpha	1	110.706	0.0001
r × alpha	2	0.333	0.7314
semilla	1	129.680	0.0001

El ajuste tiene $R^2 = 0.980$, RMSE residual = 0.012 y 5 grados de libertad residuales. Las pruebas son exploratorias: dos semillas y una respuesta acotada como F1 limitan la inferencia. Los coeficientes completos se incluyen en regression.json.

5. Predicción contrastada con entrenamiento real

La superficie propuso **r=1, alpha=32**, con F1 de validación previsto de 0.807. La medición duplicada obtuvo **0.828**, una diferencia observada menos prevista de +0.021. Se evaluó además r=64 fuera del intervalo original. Los puntos muestran las mediciones; la línea discontinua identifica la extrapolación. Un máximo matemático no se acepta sin esta comprobación.

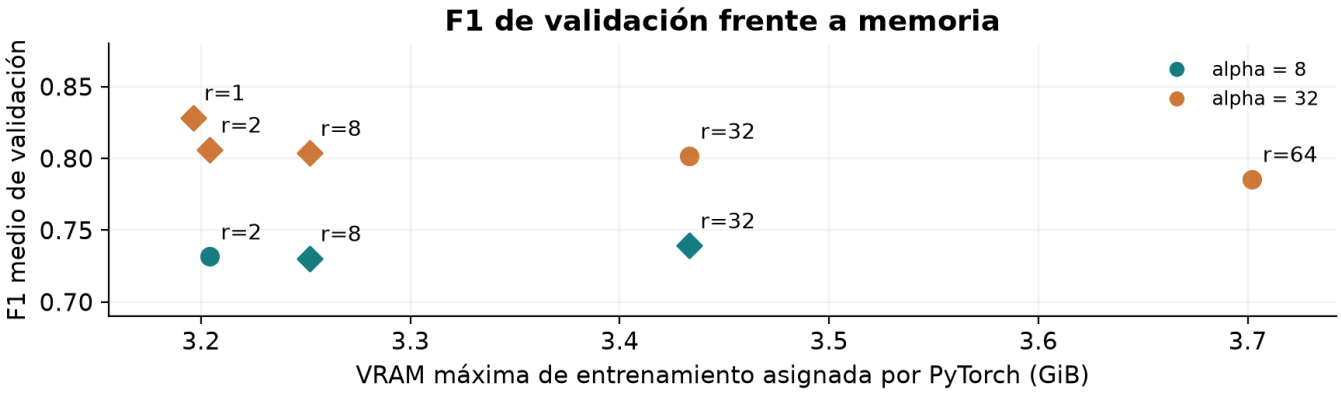
El candidato se obtiene solo con las doce validaciones originales. Las nuevas mediciones se usan después para actualizar la elección. La prueba y los 128 casos nuevos no intervienen en esa decisión.

Frontera de mejora y recursos

6. Diferencias marginales y costo

Se fijó **0.02 de F1 macro** como mejora mínima de interés práctico. Se comparan aumentos de rango mediante remuestreo pareado de casos y de las dos semillas observadas. Una p no significativa no demuestra saturación. El criterio exige que el límite superior unilateral del 95 % quede bajo 0.02 para acotar una mejora relevante.

Alpha	Cambio de r	Cambio de F1	IC 95 %	Límite sup. 95 %
8	2 a 8	-0.001	[-0.048, +0.045]	+0.037
8	8 a 32	+0.009	[-0.005, +0.045]	+0.039
32	1 a 2	-0.022	[-0.084, +0.029]	+0.017
32	2 a 8	-0.002	[-0.039, +0.032]	+0.020
32	8 a 32	-0.002	[-0.064, +0.054]	+0.042
32	32 a 64	-0.016	[-0.068, +0.033]	+0.023



Dos semillas por punto. Diamantes: no dominadas en F1, tiempo y memoria. Eje F1 ampliado.

Al pasar de r=1 a r=2 con alpha=32, la diferencia media en validación fue -0.022. Su límite superior unilateral del 95 % fue 0.017, menor que el margen práctico de 0.02. En este tramo, con los casos y semillas medidos, los resultados no justifican aumentar el rango para buscar una ganancia de 0.02 o más.

7. Configuración recomendada

Se elige r=1, alpha=32, con F1 medio de validación 0.828. La regla conserva las configuraciones a menos de 0.02 del máximo observado y elige el menor rango; el tiempo medio resuelve empates. Es un óptimo práctico bajo una tolerancia declarada, no una prueba automática de equivalencia. La frontera de Pareto de cells.csv usa desempeño, VRAM y tiempo.

La VRAM es el pico asignado por PyTorch al proceso. El calentamiento de kernels se registra aparte, sin actualizar pesos, y no se incluye en el tiempo de entrenamiento. El costo simulado es segundos / 3 600 a USD 1/h: no es una tarifa de Khipu y excluye descarga, cola e inferencia.

Comparación de tecnologías de PEFT

8. DoRA, rsLoRA y LoRA+ frente a LoRA

Se compara el LoRA seleccionado con tres métodos posteriores implementados en Hugging Face PEFT. Todos se entrenan realmente en Khipu, con el mismo rango, alpha, datos, presupuesto y semillas 42 / 43. Cada adaptador parte del modelo original.

Método	Fundamento	Implementación PEFT
LoRA	Actualización de bajo rango. Escala alpha/r.	LoraConfig estándar.
DoRA	Separa magnitud y dirección de los pesos.	use_dora=True
rsLoRA	Estabiliza la escala al usar alpha/sqrt(r).	use_rslora=True
LoRA+	Usa tasas de aprendizaje distintas para A y B.	create_loraplus_optimizer; B/A=16.

LoRA+ conserva AdamW y usa tasa máxima A=0.0002 y B=0.0032, con razón 16 tomada del ejemplo oficial. El multiplicador coseno se aplica a cada grupo para conservar la razón durante los 32 pasos; los historiales la verifican. Las tasas distintas son parte del método. Los hiperparámetros se comparten desde la selección de LoRA: no se busca por separado el mejor ajuste de cada tecnología.

Método	F1 prueba	Tiempo (min)	VRAM (GiB)	Latencia (s)	USD simulados
LoRA	0.891	3.74	3.20	1.97	0.0624
DoRA	0.890	10.88	3.48	12.36	0.1813
rsLoRA	0.883	5.39	3.19	2.09	0.0899
LoRA+	0.722	5.27	3.20	2.21	0.0879

Con 32 actualizaciones, LoRA+ obtuvo F1 de prueba 0.722, frente a 0.891 de LoRA. La razón de tasas se fijó en 16; no se evaluó si otra razón o un entrenamiento más largo cambiaría este resultado.

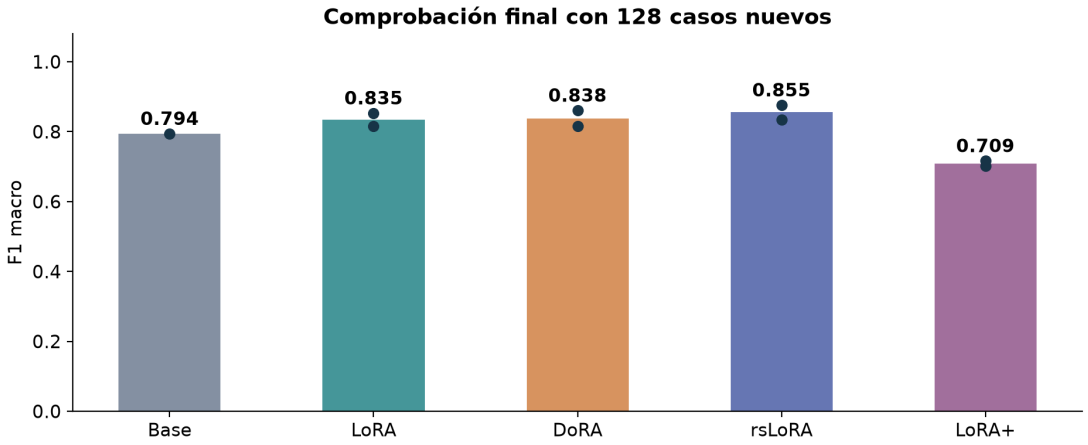
Valores medios de las dos réplicas. DoRA requiere 2.91 veces el tiempo y 1.09 veces la VRAM de LoRA. Los adaptadores se evalúan sin fusionar. PEFT recomienda fusionar DoRA para reducir su sobrecosto de inferencia; esa variante requeriría otra medición.

Las variantes rsLoRA y LoRA+ no agregan dimensiones a las matrices respecto de LoRA con el mismo rango. Sus cambios afectan el escalamiento o el aprendizaje. Un método posterior no garantiza una mejora en esta tarea; la decisión debe apoyarse en desempeño y recursos medidos.

Con r=1, alpha/r y alpha/sqrt(r) coinciden. Las diferencias observadas en ese rango no se atribuyen al escalamiento; se fijaron semillas sin forzar kernels deterministas. Se agregó un control duplicado con r=32: LoRA obtuvo F1 de validación 0.802 y prueba 0.875; rsLoRA, 0.824 y 0.854, respectivamente. Este control no cambia la configuración compartida ni usa la confirmación para seleccionar.

Comprobación final y conclusiones

9. Evaluación con 128 casos nuevos



Barra: media. Puntos: semillas 42 y 43. El modelo base no se entrena.

Método	F1 medio	Rec. crítica	Esquema válido	Exactitud total
Base	0.794	81.2 %	96.1 %	57.0 %
LoRA	0.835	85.9 %	100.0 %	75.4 %
DoRA	0.838	87.5 %	100.0 %	75.4 %
rsLoRA	0.855	90.6 %	100.0 %	77.3 %
LoRA+	0.709	90.6 %	100.0 %	56.6 %

La recuperación crítica es la proporción de tareas críticas identificadas correctamente. La exactitud total exige acertar los cuatro campos del JSON. Un formato válido no garantiza una prioridad correcta.

Error concreto, semilla 42: confirmation-0060. prioridad: esperado critica, observado media; escalamiento: esperado sí, observado no; criterio: esperado impacto, observado dependencia. El notebook conserva el texto y los hechos del caso para revisar la decisión.

La tabla informa medias de las dos réplicas; el modelo base no se entrena. Entre los métodos con rango y alpha compartidos, la mayor media de validación corresponde a **DoRA**. El notebook muestra las diferencias pareadas de los tres métodos frente a LoRA, con intervalos individuales del 95 % exploratorios, sin ajuste por multiplicidad. La confirmación no decide hiperparámetros.

La mayor media descriptiva en confirmación corresponde a rsLoRA. Este cambio de orden entre conjuntos muestra incertidumbre; no se usa para cambiar la selección.

La configuración r=1, alpha=32 responde a un criterio explícito de utilidad frente a recursos. La comprobación fuera del dominio evita aceptar el óptimo de la regresión sin medirlo. El alcance sigue siendo local: política sintética, 256 ejemplos y 32 actualizaciones. Dos semillas y una GPU compartida restringen la precisión; la transferencia a solicitudes reales requiere anotación humana independiente.

Fuentes y reproducción

Material del docente en originales/, con atribución del generador a Javier Ideami. Video y transcripciones: youtube.com/watch?v=EYKfpKXErtQ. Qwen: huggingface.co/Qwen/Qwen3.5-4B. DoRA: arxiv.org/abs/2402.09353. rsLoRA: arxiv.org/abs/2312.03732. LoRA+: arxiv.org/abs/2402.12354. Implementaciones: huggingface.co/docs/peft/en/package_reference/lora. Khipu: docs.khipu.utec.edu.pe.

La entrega contiene tres notebooks ejecutados, plan, código, datos, predicciones, versiones y adaptadores seleccionados. Repetir con run_factorial.slurm y luego run_peft.slurm, según README.md. Se agradece al HPC Khipu de UTEC por los recursos computacionales.