Trabajo/Hackathon 9: Transfer Learning y Meta-Learning con Fast-Food-101

En equipos de hasta 5 personas:

Introducción

En este trabajo grupal, los estudiantes implementarán un sistema avanzado de clasificación de imágenes combinando dos paradigmas fundamentales del aprendizaje moderno: **Transfer Learning** y **Meta-Learning**.

El proyecto se desarrollará utilizando un subconjunto del dataset **Food-101**, enfocándose únicamente en las categorías de comida rápida: chicken_wings, hamburger, hot_dog, pizza, sushi y tacos. El objetivo es construir un sistema capaz de clasificar imágenes alimenticias reutilizando conocimiento previamente aprendido en grandes datasets visuales y posteriormente combinando múltiples modelos mediante técnicas de aprendizaje de nivel superior.

El trabajo estará dividido en **dos fases experimentales complementarias**.

En la primera fase, los estudiantes aplicarán **Transfer Learning** utilizando modelos preentrenados en **ImageNet**, como ResNet, EfficientNet, DenseNet o MobileNet. Cada modelo será ajustado al nuevo problema de clasificación y evaluado individualmente mediante **Stratified 5-Fold Cross Validation**, analizando métricas como **Precision** y **F1-score**, junto con sus medias y desviaciones estándar. Esta fase busca comprender cómo el conocimiento aprendido en dominios visuales generales puede transferirse eficientemente a una tarea específica.

En la segunda fase, los modelos entrenados previamente serán reutilizados dentro de un esquema de **Meta-Learning basado en stacking**. En lugar de depender de un único modelo, el sistema combinará múltiples predicciones usando un **meta-learner**, capaz de aprender cómo fusionar las fortalezas y debilidades de cada arquitectura individual. De esta manera, el sistema pasa de aprender únicamente sobre imágenes a aprender también cómo combinar modelos para mejorar la decisión final.

Objetivo general

Implementar y evaluar un sistema de clasificación de imágenes basado en dos fases complementarias: una fase de **Transfer Learning** utilizando modelos preentrenados en ImageNet y una fase de **Meta-Learning** basada en stacking, con el fin de analizar cómo la reutilización de conocimiento y la combinación de múltiples modelos pueden mejorar el desempeño en la clasificación de imágenes del subconjunto fast food del dataset Food-101 (chicken_wings, hamburger, hot_dog, pizza, sushi y tacos), utilizando una metodología experimental rigurosa basada en **Stratified 5-Fold Cross Validation** y métricas como **Precision** y **F1-score**.

Objetivos específicos

Al finalizar el trabajo, el grupo deberá ser capaz de:

- Comprender los fundamentos de **Transfer Learning** y **Meta-Learning** aplicados a problemas de visión por computadora.
- Implementar modelos de clasificación de imágenes utilizando arquitecturas profundas preentrenadas en **ImageNet**.
- Adaptar y realizar fine-tuning de múltiples modelos base sobre el subconjunto fast food del dataset Food-101.
- Aplicar correctamente una metodología experimental basada en **Stratified 5-Fold Cross Validation**.
- Evaluar el desempeño de modelos individuales utilizando métricas como **Precision** y **F1-score**, reportando media y desviación estándar.
- Construir un sistema de **stacking** que combine múltiples modelos base mediante un meta-learner.
- Analizar si el uso de meta-learning mejora el desempeño respecto a modelos individuales.
- Comparar distintos enfoques de ensemble y estudiar la complementariedad entre arquitecturas.
- Analizar estabilidad, generalización y variabilidad de los resultados obtenidos entre folds.
- Identificar limitaciones, errores frecuentes y desafíos asociados al uso de transfer learning y meta-learning en clasificación visual.
- Desarrollar un pipeline experimental reproducible, documentado y correctamente estructurado en un Jupyter Notebook.

Dataset

Fast-Food-101: El trabajo utilizará un subconjunto del conjunto de datos público **Food-101,** ampliamente utilizado en tareas de clasificación de imágenes y visión por computadora.

Food-101 contiene originalmente:

- 101 categorías de comida
- 101 000 imágenes
- Aproximadamente:
    - 750 imágenes de entrenamiento por clase
    - 250 imágenes de prueba por clase

Las imágenes presentan:

- alta variabilidad visual,
- diferentes condiciones de iluminación,
- cambios de perspectiva,
- oclusiones,
- ruido visual,
- y fondos complejos.

Además, el dataset es conocido porque parte de las imágenes de entrenamiento contienen cierto nivel de ruido o etiquetas imperfectas, lo que lo convierte en un escenario interesante para evaluar la capacidad de generalización de modelos de aprendizaje profundo.

Subconjunto utilizado

Para reducir el costo computacional y facilitar el análisis experimental, en este trabajo se utilizará únicamente un subconjunto relacionado con comida rápida (fast food): fast_food.zip

Las clases seleccionadas son:

- chicken_wings
- hamburger
- hot_dog
- pizza
- sushi
- tacos

De esta manera, el problema de clasificación será de **6 clases.**

Justificación de selección
Las categorías seleccionadas presentan características visuales interesantes para clasificación automática:

- Algunas clases poseen patrones visuales muy distintivos (ej. pizza).
- Otras presentan alta similitud visual (ej. hamburger vs. hot_dog).
- Existen variaciones importantes en:
    - forma,
    - textura,
    - ingredientes,
    - iluminación,
    - ángulo de captura,
    - y presentación del alimento.

Esto genera un escenario adecuado para:

- evaluar transferencia de conocimiento desde ImageNet,
- analizar complementariedad entre modelos,
- y estudiar cómo el stacking puede mejorar la clasificación final.

Actividades

El desarrollo del trabajo estará dividido en dos fases principales: Transfer Learning y Meta-Learning, ambas utilizando el mismo subconjunto del dataset Fast-Food-101.

Fase 1 — Transfer Learning

En esta fase, el grupo deberá entrenar y evaluar múltiples modelos preentrenados en ImageNet de manera individual.

Actividad 1 - Exploración

- Verificar el balance entre clases.
- Mostrar ejemplos visuales de cada categoría.

Actividad 2 — Preprocesamiento y Data Augmentation

El grupo deberá implementar un pipeline de preprocesamiento adecuado para modelos preentrenados en ImageNet.
Debe incluir:

- Redimensionamiento de imágenes
- Normalización compatible con ImageNet
- Conversión a tensores

Además, deberán implementar técnicas de data augmentation, por ejemplo:

- Random Horizontal Flip
- Random Rotation
- Random Crop
- Random Resized Crop
- Color Jitter

El grupo debe justificar:

- qué técnicas fueron usadas,
- por qué fueron seleccionadas,
- y cómo podrían ayudar a la generalización.

Actividad 3 — División experimental

El trabajo debe implementar obligatoriamente: **Stratified 5-Fold Cross Validation**
El grupo deberá:

- Implementar Stratified K-Fold con: k = 5
- Garantizar que cada fold preserve la proporción de clases.
- Explicar por qué se usa validación estratificada.
- Evitar data leakage entre folds.

Actividad 4 — Implementación de modelos base

El grupo deberá implementar al menos 3 modelos preentrenados en ImageNet.
Opciones sugeridas:

- ResNet50
- EfficientNetB0/B3
- DenseNet121
- MobileNetV2
- Vision Transformer

Para cada modelo deberán:

- cargar pesos preentrenados,
- reemplazar la capa final,
- decidir que capaz congelar
- adaptar el modelo a 6 clases,
- realizar fine-tuning,
- definir hiperparámetros.

Actividad 5 — Evaluación individual de modelos
Cada modelo deberá evaluarse usando: **Precision, F1-score.**
Los resultados deben reportarse como: **Mean, Standard Deviation** sobre los 5 folds.

El notebook debe incluir:

- tablas comparativas,
- matrices de confusión,
- curvas de entrenamiento.

Fase 2 — Meta-Learning con Stacking

En esta fase, el grupo reutilizará los modelos entrenados previamente para construir un sistema de stacking.

Actividad 6 — Generación del dataset meta
El grupo deberá:

- obtener las predicciones de cada modelo base,
- extraer probabilidades o logits,
- concatenar las salidas,
- construir un nuevo dataset meta.

Debe explicarse:

- cómo se generan las entradas del meta-learner,
- y cómo evitar data leakage durante stacking.

Actividad 7 — Implementación del meta-learner

El grupo deberá implementar al menos un meta-modelo.
Opciones sugeridas:

- Logistic Regression
- Random Forest
- XGBoost

El meta-modelo debe aprender a combinar las predicciones de los modelos base.

Actividad 8 — Evaluación del sistema de stacking

El sistema final deberá evaluarse usando:

- Precision
- F1-score
- Mean
- Standard Deviation

sobre los mismos 5 folds.

Además, el grupo deberá comparar: Mejor modelo individual vs Stacking

Actividad 9 — Comparación y análisis crítico

El grupo deberá analizar:

- ¿Qué modelo individual tuvo mejor desempeño?
- ¿El stacking mejoró realmente los resultados?
- ¿Qué modelos parecen complementarse mejor?
- ¿Qué clases generan más errores?
- ¿Qué indica la desviación estándar sobre estabilidad?
- ¿Existen signos de sobreajuste?

Entregables

Cada grupo debe entregar 1 Jupyter Notebook (.ipynb) funcional con las especificaciones solicitadas en la sección anterior.

Asignación de nota por desempeño en ambas métricas.

1er puesto. 20 puntos.
2do puesto. 19 puntos.
3er puesto. 18 puntos.
4to y 5to puesto. 17 puntos.
6to y 7to puesto. 16 puntos.

Rúbrica de evaluación referencial

Criterio	Descripción
Preparación y manejo del dataset	Preprocessing adecuado, data augmentation bien justificada y correcta implementación de Stratified 5-Fold Cross Validation evitando data leakage.
Implementación de Transfer Learning	Uso correcto de modelos preentrenados en ImageNet, adaptación a la nueva tarea, fine-tuning y entrenamiento funcional de múltiples modelos base.
Implementación de Meta-Learning	Correcta construcción del sistema de stacking, generación del dataset meta, entrenamiento del meta-learner y combinación adecuada de modelos.
Evaluación experimental	Uso correcto de métricas (Precision y F1-score), reporte de mean y standard desviation, comparación entre folds y análisis cuantitativo adecuado.
Análisis crítico e interpretación	Reflexión sobre resultados, estabilidad, sesgo-varianza, limitaciones, errores frecuentes, complementariedad entre modelos y posibles mejoras futuras.

Claridad y organización del notebook	Notebook ordenado, reproducible, bien comentado, visualmente claro y fácil de seguir. Incluye diagramas, tablas y explicaciones adecuadas.