Hackaton 11: ¿Confiar, Verificar o Escalar?

Profesores: Dra. Aurea Soriano-Vargas. Mg. Robert Buleje

En equipos de hasta 5 personas:

Contexto

Las instituciones financieras utilizan sistemas de Inteligencia Artificial para evaluar solicitudes de crédito y estimar el riesgo de incumplimiento de los clientes. Sin embargo, una decisión automática incorrecta puede generar pérdidas económicas, discriminación o rechazo injustificado de solicitantes.

En la práctica, los mejores sistemas no buscan reemplazar completamente a los analistas humanos, sino colaborar con ellos. Las decisiones de bajo riesgo pueden automatizarse, mientras que los casos más inciertos requieren revisión humana.

En este hackatón, los estudiantes diseñarán un sistema de colaboración Humano–IA capaz de decidir cuándo confiar en la IA y cuándo solicitar intervención humana, utilizando medidas de incertidumbre basadas en entropía y técnicas de explicabilidad.

Dataset: Statlog (German Credit Data)

El Statlog German Credit Dataset es uno de los conjuntos de datos clásicos para evaluación de riesgo crediticio y ha sido ampliamente utilizado en investigación sobre clasificación, explicabilidad, equidad y toma de decisiones automatizadas.

Link: https://archive.ics.uci.edu/dataset/144/statlog+german+credit+data

El dataset contiene información de 1,000 solicitantes de crédito descritos mediante 20 atributos financieros, demográficos y laborales.

El objetivo es predecir si un solicitante representa un:

- Buen riesgo crediticio (Good Credit Risk)
- Mal riesgo crediticio (Bad Credit Risk)

La distribución de clases es:

Clase	Instancias
Buen crédito	700

Mal crédito	300

Variables Disponibles

Entre las variables incluidas se encuentran:

- Estado de cuenta bancaria
- Duración del crédito
- Historial crediticio
- Propósito del préstamo
- Monto solicitado
- Cuenta de ahorro
- Antigüedad laboral
- Tasa de endeudamiento
- Estado civil
- Existencia de avalistas
- Tiempo de residencia
- Propiedades
- Edad
- Planes de pago existentes
- Tipo de vivienda
- Número de créditos activos
- Personas dependientes
- Empleo
- Teléfono
- Trabajador extranjero

Las variables combinan información financiera y personal, simulando un escenario real de evaluación de riesgo.

Objetivos de Aprendizaje

Al finalizar este hackatón, el estudiante será capaz de:

- Construir modelos de clasificación para problemas de riesgo crediticio.
- Calcular incertidumbre predictiva mediante entropía.
- Analizar la relación entre incertidumbre y errores del modelo.
- Diseñar políticas de colaboración Humano–IA basadas en niveles de confianza.
- Aplicar técnicas de explicabilidad para justificar decisiones automatizadas.
- Evaluar experimentalmente el impacto de la intervención humana en sistemas inteligentes.

- Comprender el concepto de appropriate reliance y sus implicancias en aplicaciones de alto impacto.

Objetivo del Hackatón

Diseñar e implementar un sistema inteligente de colaboración Humano–IA capaz de determinar cuándo una decisión crediticia debe ser tomada automáticamente por la IA y cuándo debe ser escalada a un analista humano, utilizando medidas de incertidumbre para maximizar la calidad de las decisiones y minimizar el costo de intervención humana.

Competencia: ¿Quién gana?

Cada equipo reportará una puntuación final basada en un indicador compuesto.

Métrica principal: Human-AI Collaboration Score (HACS)

Se define:

$$HACS = 0.6 \times F1 + 0.2 \times Coverage + 0.2 \times Efficiency$$

donde:

F1: Desempeño final del sistema colaborativo.

$0 \leq F1 \leq 1$

Coverage: Porcentaje de casos resueltos automáticamente por la IA.

$$Coverage = \frac{\text{Casos resueltos por IA}}{\text{Total de casos}}$$

Ejemplo:

- 800 casos IA
- 200 casos humanos

$Coverage = 0.8C$

Efficiency: Mide cuánto trabajo humano se evitó.

$$Efficiency = 1 - \frac{\text{Casos revisados por humanos}}{\text{Total de casos}}$$

Ejemplo

Equipo A

Métrica	Valor
F1	0.89

Coverage	0.30
Efficiency	0.30

HACS=0.654

Equipo B

Métrica	Valor
F1	0.87
Coverage	0.75
Efficiency	0.75

HACS=0.846

Gana el Equipo B porque logra casi el mismo desempeño usando mucho menos trabajo humano.

Condición para ganar

Un equipo será descalificado del ranking principal si:

- Su sistema colaborativo no supera a la IA sola.
- No utiliza incertidumbre basada en entropía.
- No justifica los umbrales de escalamiento.
- No presenta análisis de explicabilidad.

De esta forma, los estudiantes no compiten por entrenar el mejor clasificador, sino por construir el **mejor equipo Humano–IA**, que es precisamente el objetivo de la clase de colaboración entre humanos e inteligencia artificial.

Condición para ganar

1° puesto. 20 puntos + 10 puntos de participación.
2° puesto. 19 puntos + 8 puntos de participación.
3° puesto. 18 puntos + 6 puntos de participación.
4° y 5° puesto. 17 puntos + 4 puntos de participación.
6 y 7° puesto. 16 puntos + 4 puntos de participación.

Suscripción máxima del resultado: miércoles 4 de noviembre a las 4:50 p.m.

Entrega máxima del notebook. Medianoche 4 de noviembre.

Actividades del Hackatón

Parte 1 – Comprensión del Problema y Exploración de Datos (10%)

Actividad 1.1 – Comprensión del problema

Analicen el contexto del problema de evaluación crediticia y respondan:

1. ¿Por qué una clasificación incorrecta puede generar pérdidas para una institución financiera?
2. ¿Qué consecuencias podría tener rechazar incorrectamente a un buen cliente?
3. ¿Qué consecuencias podría tener aprobar incorrectamente a un cliente de alto riesgo?

Actividad 1.2 – Exploración del Dataset

Realicen un análisis exploratorio del conjunto de datos.

Como mínimo:

- Número de instancias.
- Número de variables.
- Distribución de clases.
- Variables categóricas y numéricas.
- Valores faltantes.
- Correlaciones relevantes.
- Estadísticas descriptivas.

Visualizaciones sugeridas:

- Histograma de edades.
- Distribución de duración de créditos.
- Distribución de clases.
- Matriz de correlación.

Parte 2 – Desarrollo del Modelo Base (20%)

Actividad 2.1 – Preprocesamiento

Realicen todas las transformaciones necesarias:

- Tratamiento de valores faltantes.
- Codificación de variables categóricas.
- Escalamiento si corresponde.
- División Train/Test.

Actividad 2.2 – Entrenamiento

Entrenen al menos dos modelos diferentes:

- Random Forest
- XGBoost
- LightGBM
- CatBoost
- Gradient Boosting

Seleccionen el mejor modelo.

Actividad 2.3 – Evaluación

Reporten:

- Accuracy
- Precision
- Recall
- F1-score
- ROC-AUC

Presenten:

- Matriz de confusión.
- Curva ROC.

Parte 3 – Cuantificación de Incertidumbre (20%)

Actividad 3.1 – Obtención de Probabilidades

Utilicen el modelo seleccionado para generar probabilidades para cada instancia del conjunto de prueba.

Actividad 3.2 – Cálculo de Entropía

Implementen la incertidumbre basada en entropía:

$$H(x) = -p \log(p) - (1-p) \log(1-p)$$

Calculen la incertidumbre para cada predicción.

Actividad 3.3 – Análisis de Incertidumbre

Generen:

- Histograma de incertidumbre.
- Boxplot de incertidumbre para aciertos y errores.
- Curva Accuracy vs Uncertainty.

Actividad 3.4 – Análisis Estadístico

Comparen:

- Incertidumbre promedio de predicciones correctas.
- Incertidumbre promedio de predicciones incorrectas.

Discutan:

¿La incertidumbre es realmente útil para identificar errores del modelo?

Parte 4 – Diseño del Sistema Humano–IA (25%)

Actividad 4.1 – Definición de Umbrales

Diseñen una política basada en incertidumbre.

Ejemplo:

Incertidumbre	Acción
Baja	IA decide
Media	Analista Junior
Alta	Analista Senior

Los umbrales deben justificarse utilizando evidencia experimental.

Actividad 4.2 – Simulación de Analistas

Considere:

Analista	Precisión
Junior	70%
Senior	95%

Implemente la simulación.

```
import numpy as np

def simulate_human_decision(y_true, accuracy=0.7, random_state=42):
    rng = np.random.default_rng(random_state)

    y_true = np.array(y_true)

    # Decide si el humano acierta o falla en cada caso
    correct = rng.random(len(y_true)) < accuracy

    # Si acierta: devuelve y_true
    # Si falla: devuelve la clase opuesta
    y_human = np.where(correct, y_true, 1 - y_true)

    return y_human
```

```
y_junior = simulate_human_decision(y_test, accuracy=0.70, random_state=1)
y_senior = simulate_human_decision(y_test, accuracy=0.95, random_state=3)
```

Actividad 4.3 – Sistema Colaborativo

Construya un pipeline capaz de:

1. Calcular la incertidumbre.
2. Asignar responsable de decisión.
3. Obtener la decisión final.
4. Registrar quién tomó cada decisión.

```
def human_ai_policy(y_true, y_ai, uncertainty):
    final_decision = []
    decision_maker = []

    for true_label, ai_label, u in zip(y_true, y_ai, uncertainty):

        if u < UmbralA: #ustedes definen estos umbrales
            final_decision.append(ai_label)
            decision_maker.append("AI")

        elif u < UmbralB: #ustedes definen estos umbrales
            human_label = simulate_human_decision( [true_label],   accuracy=0.70)[0]
            final_decision.append(human_label)
            decision_maker.append("Junior")

        else:
            human_label = simulate_human_decision( [true_label],  accuracy=0.95)[0]
            final_decision.append(human_label)
            decision_maker.append("Senior")

    return np.array(final_decision), decision_maker
```

Actividad 4.4 – Evaluación

Compare:

- IA sola.
- Analista Junior.
- Analista Senior.
- Sistema Humano–IA.

Reporte:

- Accuracy
- Precision
- Recall
- F1-score

Parte 5 – Explicabilidad (15%)
Actividad 5.1 – Implementación de SHAP
Calcule explicaciones SHAP para el modelo seleccionado.

Actividad 5.2 – Casos de Estudio
Seleccione:
- 3 predicciones correctas con baja incertidumbre.
- 3 predicciones correctas con alta incertidumbre.
- 3 predicciones incorrectas.

Actividad 5.3 – Interpretación
Para cada caso:
1. ¿Qué variables tuvieron mayor impacto?
2. ¿La explicación es coherente?
3. ¿La explicación ayudaría a un analista humano?
4. ¿La explicación genera confianza o confusión?

Parte 6 – Cálculo del puntaje final HACS (10%)
Actividad 6.1 – Optimización de la Política
Modifique los umbrales de incertidumbre para maximizar el puntaje final.

Actividad 6.2 – Presentación de Resultados
Cada equipo deberá defender:
- Su modelo.
- Su estrategia de incertidumbre.
- Su política Humano–IA.p
- Los beneficios obtenidos respecto a una IA totalmente automática.

Entregables
Notebook (.ipynb) - **Solo incluir el mejor resultado.**
Debe incluir:
- Título del hackatón y nombres del equipo
- Código completo

- Visualizaciones
- Resultados
- Discusión de resultados

Rúbrica de evaluación referencial

Criterio	Descripción
Exploración y comprensión del dataset	Análisis exploratorio, identificación de patrones, distribución de clases y comprensión del problema crediticio.
Desarrollo y evaluación del modelo base	Entrenamiento, comparación y selección justificada de modelos de clasificación.
Implementación de incertidumbre basada en entropía	Cálculo correcto de la incertidumbre y explicación de su significado.
Análisis de incertidumbre	Visualizaciones y análisis de la relación entre incertidumbre y errores de predicción.
Diseño del sistema Humano–IA	Definición y justificación de la política de colaboración basada en incertidumbre.
Simulación y evaluación de analistas humanos	Implementación de la simulación y comparación entre IA, humanos y sistema colaborativo.
Explicabilidad y conclusiones	Uso de SHAP, interpretación de resultados y reflexión final fundamentada.