

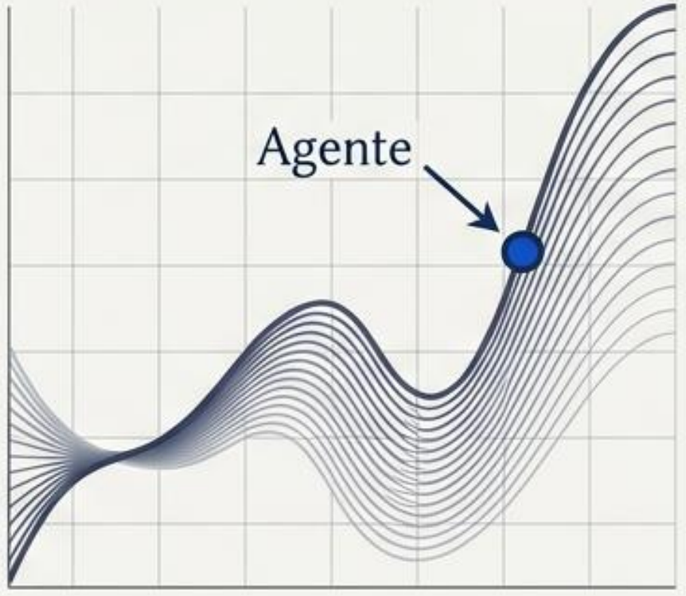
Ascenso Topográfico: La Arquitectura Matemática de Proximal Policy Optimization (PPO)

De la inestabilidad de los gradientes de política a la eficiencia del algoritmo predeterminado en RL moderno.

El Desafío de la Optimización de Políticas

- **Meta:** Maximizar la recompensa acumulada esperada $J(\theta)$.
- **Método:** Ajustar directamente los parámetros θ de la red neuronal (actor).
- **Riesgo:** Un paso de gradiente demasiado grande en el espacio de parámetros puede causar un colapso catastrófico del comportamiento.

$$\nabla_\theta J(\theta) = \mathbb{E}_{\tau \sim \pi_\theta} \left[\sum_{t=0}^{T} \nabla_\theta \log \pi_\theta(a_t|s_t) G_t \right]$$



Alta Varianza: La actualización depende de trayectorias completas τ, lo que genera un gradiente ruidoso e inestable.

El Peligro del Acantilado de Optimización (Optimization Cliff)

Región de Confianza (Trust Region)



Los gradientes de política tradicionales asumen un panorama lineal localmente. Cuando el terreno cambia bruscamente, una actualización agresiva destruye el progreso previo (pérdida de memoria catastrófica).

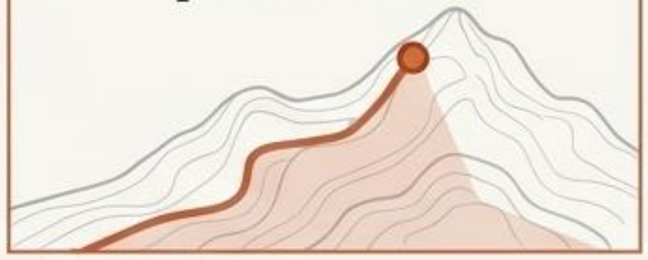
UTEC
UNIVERSIDAD DE INGENIERÍA Y TECNOLOGÍA

Aislando la Señal: La Función de Ventaja A(s,a)

$$A(s,a) = Q(s,a) - V(s)$$

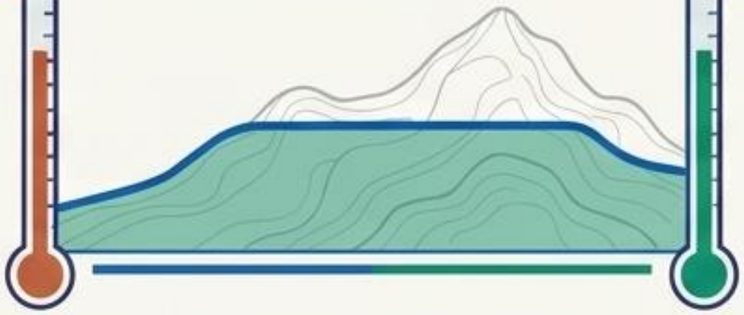
Valor Absoluto

El valor de tomar la acción *a* en el estado *s* y seguir la política actual.



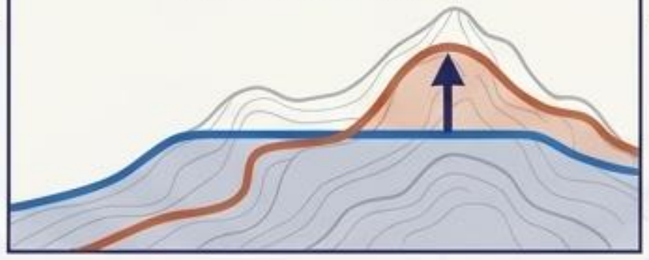
Línea Base (Baseline)

El valor promedio esperado de estar simplemente en el estado *s*.



Valor Relativo

¿Fue esta acción mejor o peor de lo que esperábamos normalmente?

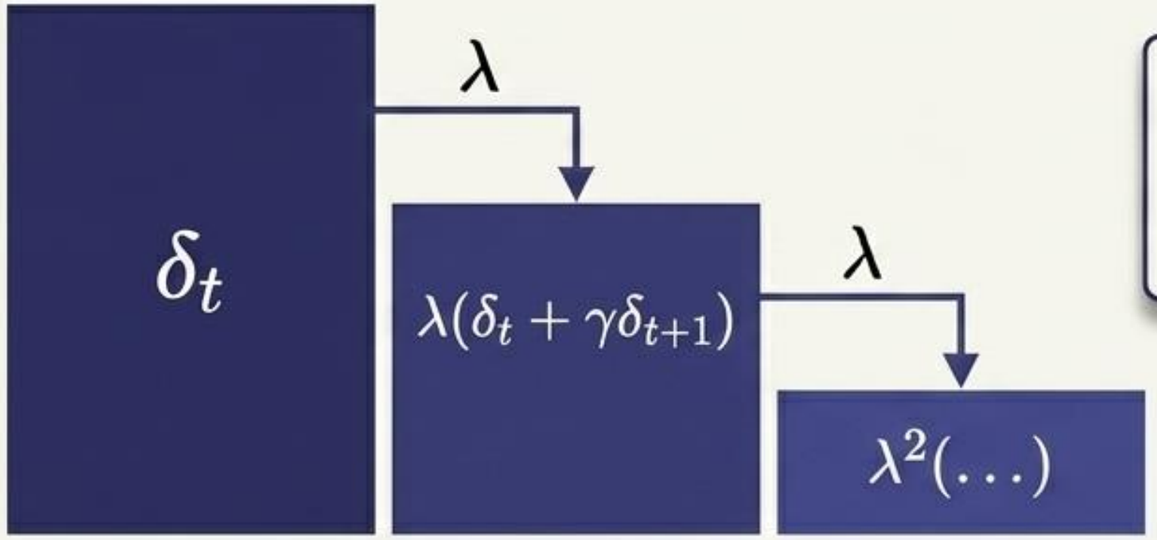


Concepto Clave: Restar la línea base reduce enormemente la varianza sin sesgar el gradiente esperado, aislando el impacto real de la acción.

Generalized Advantage Estimation (GAE)

Error TD Base (Estimación miope de 1 paso)

$$\delta_t = r_t + \gamma\, V(s_{t+1}) - V(s_t)$$



El hiperparámetro λ pesa la importancia de las recompensas futuras frente a los errores de predicción inmediatos.

La Suma Infinita GAE

$$\hat{A}_t^{\text{GAE}} = \sum_{l=0}^{\infty} (\gamma\lambda)^l \delta_{t+l}$$

El Espectro Sesgo-Varianza en GAE



Error TD de 1 paso $\hat{A}_t = \delta_t$



Alto Sesgo, Baja Varianza

Retorno Monte Carlo puro



Sin Sesgo, Alta Varianza

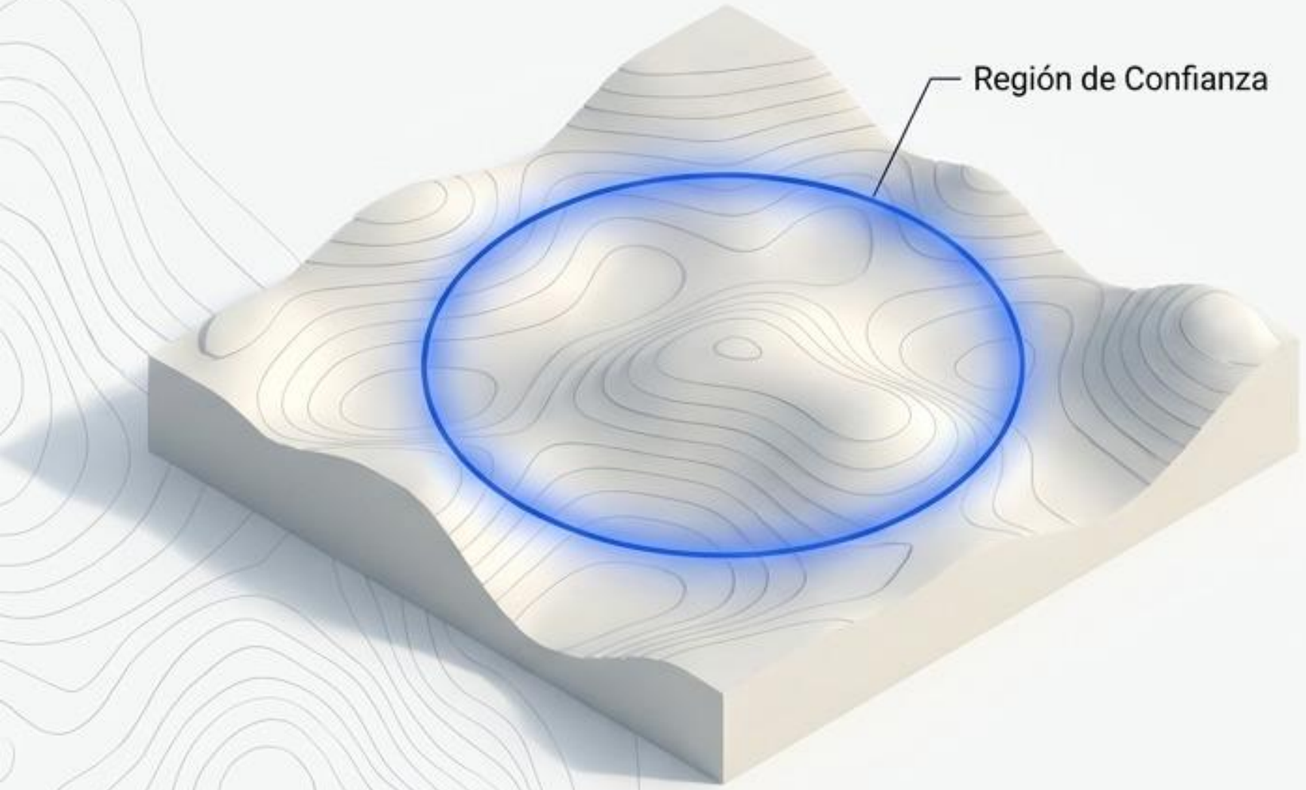
PPO utiliza GAE para equilibrar matemáticamente este compromiso empíricamente, combinando precisión direccional con estabilidad numérica.

Matriz de Diagnóstico: Estimadores de Ventaja

Método	Fórmula	Varianza	Sesgo	Eficiencia Temporal
Retorno Empírico Monte Carlo	$G_t - V(s)$	⚠ Alta	✓ Nulo	Uso de trayectoria completa
TD-Error 1-step	δ_t	✓ Baja	⚠ Alto	1 paso a futuro
TD(λ) / GAE	$\hat{A}^{GAE}$	✓ Controlable	✓ Controlable	Parámetro de decaimiento

Takeaway: GAE es la única técnica que permite parametrizar y optimizar directamente el *trade-off* entre sesgo y varianza, convirtiéndose en el motor de estimación estándar para PPO.

La Solución Estricta: Trust Region Policy Optimization (TRPO)



Objetivo Sustituto (Maximizar probabilidad de buenas acciones respecto a la antigua política)

$$\max_{\theta} \mathbb{E}_t \left[\frac{\pi_\theta(a|s)}{\pi_{\theta_{\text{old}}}(a|s)} \hat{A}_t \right]$$

El Muro de Seguridad (Restricción Kullback-Leibler)

$$\text{sujeto a } \mathbb{E}_t \left[D_{KL}(\pi_{\theta_{\text{old}}} \,\|\, \pi_\theta) \right] \leq \delta$$

Garantiza matemáticamente que la nueva distribución de probabilidad no se aleje más de δ de la antigua.

El Cuello de Botella Computacional de TRPO



Derivadas de Segundo Orden

TRPO requiere calcular la matriz Hessiana de la divergencia KL, no solo gradientes simples.

$$\frac{\partial^2}{\partial z} H(D_{\mathrm{KL}})$$

El Peso de la Matriz

Para redes modernas (ej. LLMs con miles de millones de parámetros N), invertir una matriz $N \times N$ requiere computación de orden $O(N^3)$.

$$\boxed{O(N^3)}$$

Aproximación Iterativa

Requiere utilizar el lento Método del Gradiente Conjugado en cada paso de actualización para ser mínimamente viable.

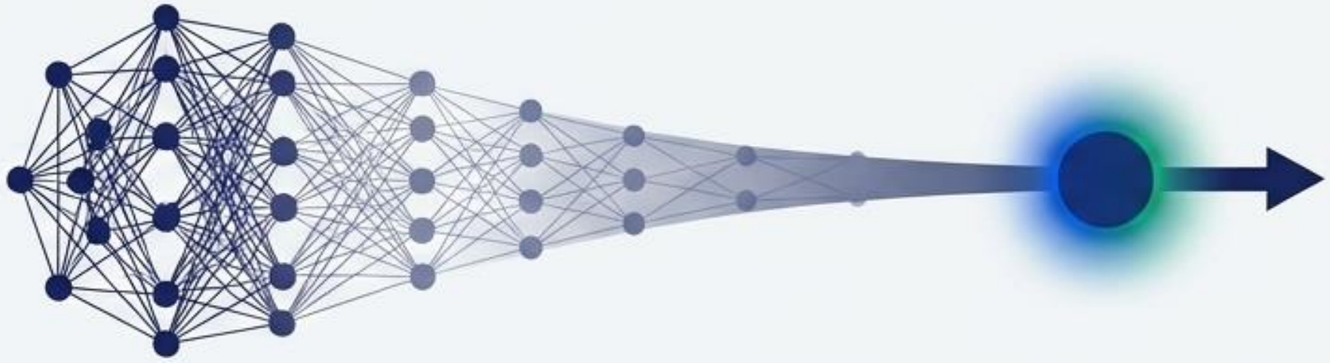


Conclusión: TRPO garantiza la mejora monótona en papel, pero es prohibitivamente complejo e insoportablemente lento para el Deep Learning profundo.

UTEC
UNIVERSIDAD DE INGENIERÍA Y TECNOLOGÍA

PPO: Estabilidad de Segundo Orden con Eficiencia de Primer Orden

KL Divergence & Matriz Hessiana



El Ratio de Probabilidad

El Ratio de Probabilidad: $r_t(\theta) = \dfrac{\pi_\theta(a_t|s_t)}{\pi_{\theta_{old}}(a_t|s_t)}$.

↑ Si $r_t(\theta) > 1$: La nueva política favorece esta acción.

↓ Si $r_t(\theta) < 1$: La nueva política penaliza esta acción.

= Si $r_t(\theta) = 1$: Ambas políticas son idénticas.

El Cambio de Paradigma: En lugar de calcular matrices masivas para medir distancias, PPO simplemente observa y limita directamente este ratio escalar mediante recortes.

UTEC
UNIVERSIDAD DE INGENIERÍA Y TECNOLOGÍA

Anatomía de la Ecuación PPO-Clip

$$\mathcal{L}^{\text{CLIP}}(\theta) = \mathbb{E}_t \left[\min \left(r_t(\theta)\hat{A}_t, \text{clip}(r_t(\theta), 1-\epsilon, 1+\epsilon)\hat{A}_t \right) \right]$$

El Objetivo No Restringido

$r_t(\theta)\hat{A}_t$

Sube la probabilidad si la Ventaja es positiva (y viceversa).

El Mecanismo de Recorte

$\text{clip}(r_t(\theta), 1-\epsilon, 1+\epsilon)$

Fuerza matemática bruta. No permitas que el ratio supere el hiperparámetro ϵ (típicamente 0.2).

El Límite Pesimista

$\min(\dots)$

Toma el **valor mínimo** entre el ratio libre y el recortado. Ignora cualquier mejora ilusoria más allá del límite seguro.

UTEC
UNIVERSIDAD DE INGENIERÍA Y TECNOLOGÍA

La Lógica del Recorte Asimétrico

	Ventaja Positiva ($\hat{A}_t > 0$)	Ratio Baja ($r_t < 1$)
Ratio Sube ($r_t > 1$)	¡Buena acción! Aumenta la probabilidad, pero recorta en $1+\epsilon$. (Evita sobreajuste codicioso). 	La política empeora una buena acción. El gradiente penaliza sin restricciones.
	La política fomenta una mala acción. El gradiente penaliza fuertemente sin recortes.	¡Mala acción evitada! Disminuye la probabilidad, pero recorta en $1-\epsilon$. (Evita destruir trayectorias prematuramente). 
	Ventaja Negativa ($\hat{A}_t < 0$)	

Ratio Baja ($r_t < 1$)

Eficiencia de Muestra: Reutilización Segura de Datos (Multiple Epochs)

Recolección (Rollout)

Cálculo de Ventaja

Múltiples Épocas



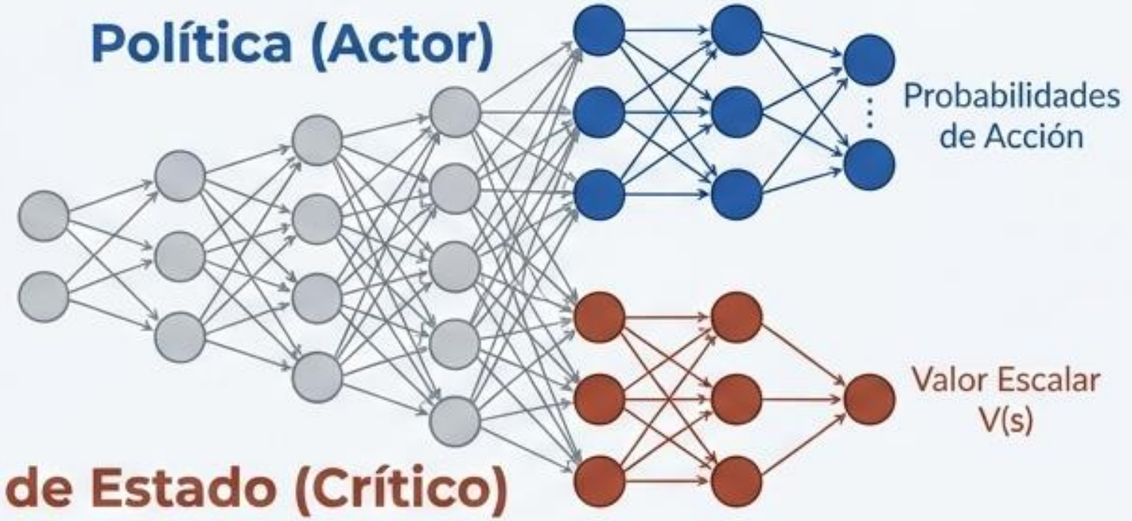
El Actor genera un Buffer de Trayectorias de tamaño fijo usando $\pi_{\theta_{old}}$.

Se evalúa GAE en todo el buffer simultáneamente.

A diferencia de métodos Vanilla (usar y tirar), el límite de PPO permite pasar el mismo buffer por la red K veces, cortado en mini-batches.

Resultado: Extracción máxima de aprendizaje por cada interacción costosa con el simulador, sin destruir la política.

La Arquitectura Actor-Crítico Completa



$$\mathcal{L}^{\text{TOTAL}} = \mathcal{L}^{\text{CLIP}}(\theta) - c_1\mathcal{L}^{\text{VF}}(\theta) + c_2 S[\pi_\theta]$$

Mejora las decisiones y la probabilidad de buenas acciones **(Actor)**.

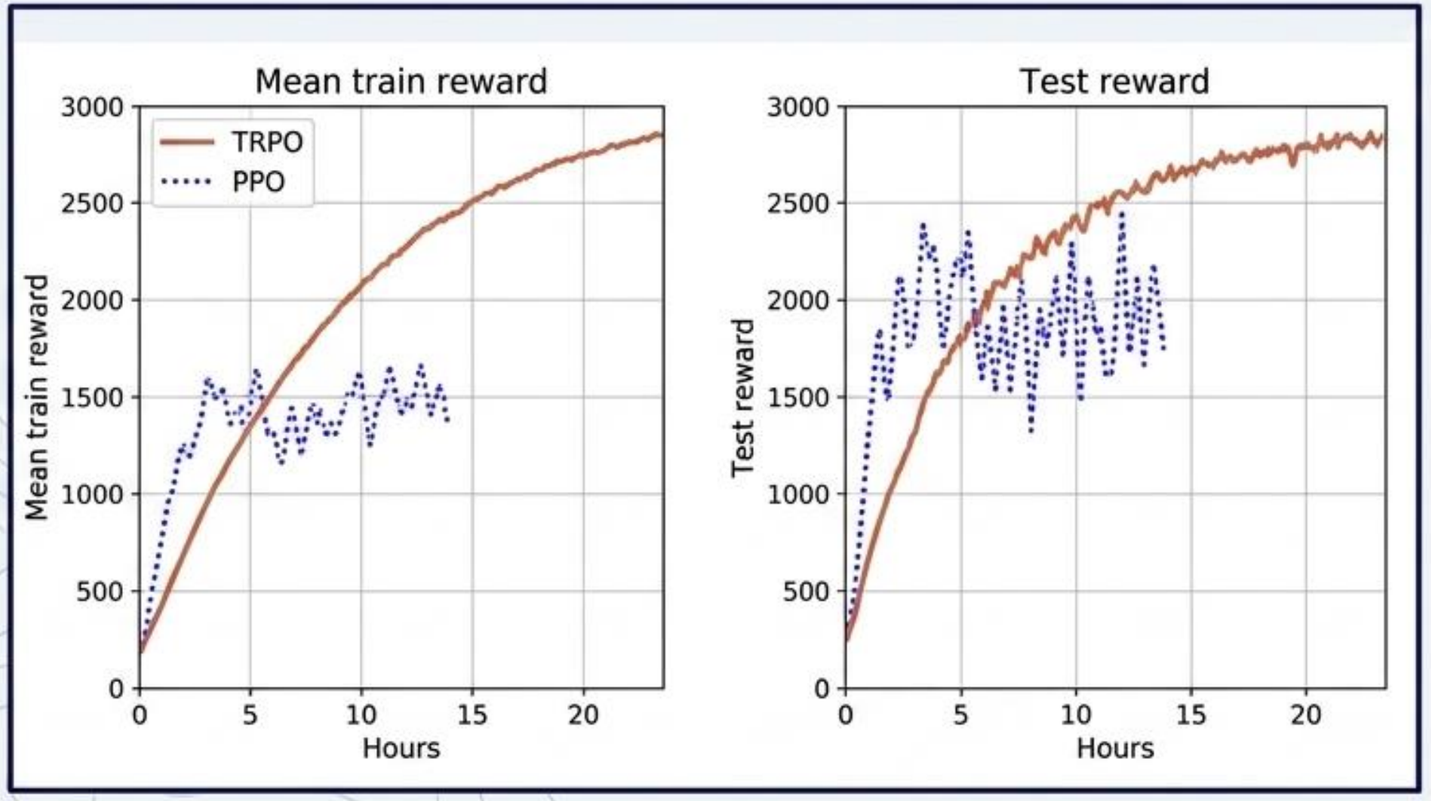
Value Function Loss: Reduce el error cuadrático medio para calibrar el baseline **V(s) (Crítico)**.

Entropy Bonus: Mantiene a la red explorando y evita la convergencia prematura.

Evolución Algorítmica: El Linaje de Optimización de Políticas

Dimensión	REINFORCE (Vanilla)	TRPO	PPO (El Estándar)
Función Objetivo	Retorno log-prob	Expectativa KL	Surrogate Clipped
Método de Optimización	Primer Orden	Segundo Orden (Fisher Matrix)	Primer Orden (SGD/Adam)
Restricción del Paso	Ninguna (Riesgo de colapso)	Estricta (Hard Constraint δ)	Suave / Asimétrica (Pessimistic ε)
Eficiencia de Muestra	Baja (1 vez por lote)	Media	Alta (Múltiples épocas)
Implementación	Muy Fácil	Extremadamente Compleja	Moderada / Elegante

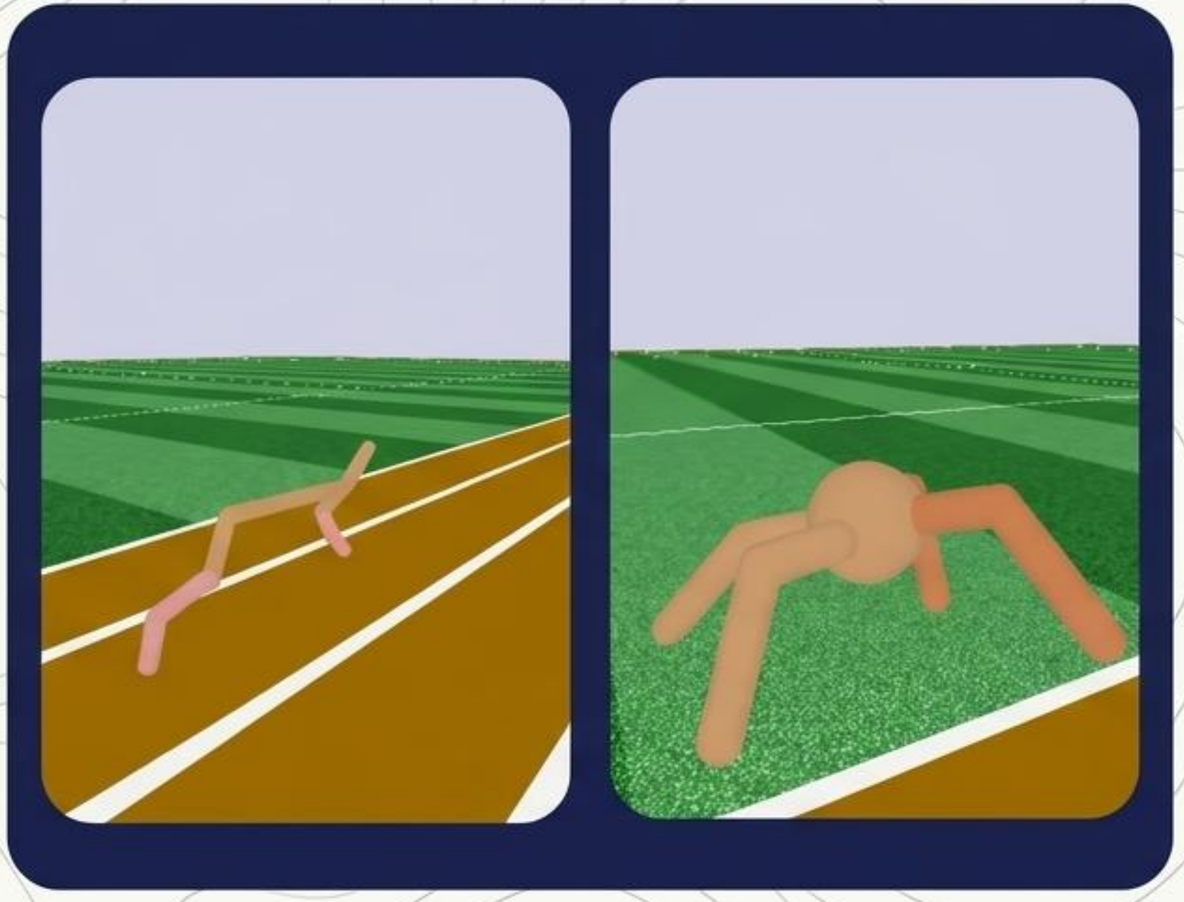
Evidencia Empírica: Convergencia Robusta



Análisis de Rendimiento

- **Competitividad:** PPO emula la estabilidad asintótica de las complejas garantías matemáticas de TRPO.
- **Velocidad:** Logra convergencia iterando mucho más rápido en tiempo de reloj (wall-clock time) debido a su optimizador de primer orden (Adam).
- **Generalización:** Muestra mejor complejidad de muestra empírica sin la sobrecarga del método de gradiente conjugado.

Casos de Éxito: Control Continuo Robótico



- **Espacios de Acción Continua:**

  Los problemas de robótica requieren emitir torques continuos en las articulaciones, no decisiones discretas.

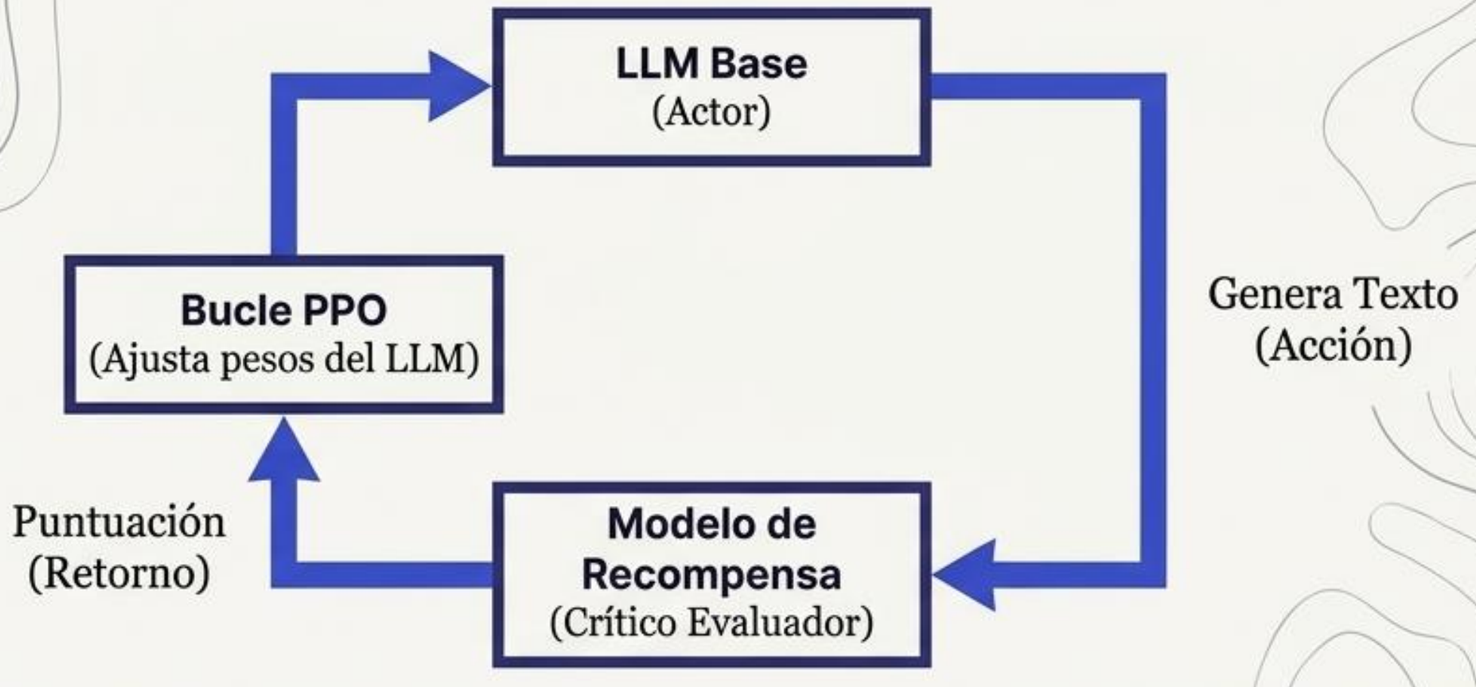
- **Distribución Gaussiana:**

  En lugar de probabilidades categóricas, PPO parametriza una distribución normal (media y desviación estándar) sobre cada actuador.

- **Prevención de Espasmos:**

  El límite de recorte asimétrico previene comandos motores extremos durante el entrenamiento, garantizando transiciones suaves y seguras hacia caminar o correr sin destrozar la física del simulador.

El Motor Detrás de ChatGPT: RLHF y PPO



Traducción al Lenguaje RL

- Estado: El contexto del prompt.
- Acción: El inmenso vocabulario de tokens.
- Política: La distribución de probabilidad de la siguiente palabra.

El Rol Crucial de PPO

El término de penalización KL en PPO evita que el LLM sufra Reward Hacking. PPO asegura que el modelo gane puntuación humana sin perder la coherencia lingüística original del preentrenamiento.

UTEC
UNIVERSIDAD DE INGENIERÍA Y TECNOLOGÍA

La Cima de la Optimización de Políticas



Reducción de Varianza

La inserción metódica de baselines y GAE enfoca el gradiente puramente en la ventaja de la acción, eliminando el ruido del entorno absoluto.

Seguridad de Actualización

El ingenioso cociente recortado (L^{CLIP}) proporciona garantías empíricas de Trust Region, eludiendo por completo el cálculo catastrófico de matrices Hessianas.

Eficiencia Operativa

El poder de reutilizar datos mediante múltiples épocas ha establecido a PPO como el motor predeterminado desde la robótica hasta el alineamiento de IAG.

PPO no es el algoritmo matemáticamente más perfecto; es el milagro de ingeniería más equilibrado.

UTEC
UNIVERSIDAD DE INGENIERÍA Y TECNOLOGÍA